

Market Regime and Risk Lab

Prévision de la volatilité future à cinq jours du BTC-USD

Projet de recherche pour portfolio

Août 2026

Résumé

Ce rapport étudie si les informations disponibles à la fin d'une journée permettent d'améliorer la prévision de la volatilité réalisée des cinq prochaines observations quotidiennes du BTC-USD. Le projet utilise des données quotidiennes OHLCV provenant de Yahoo Finance, des variables construites à partir des rendements, de la volatilité et des drawdowns, une baseline fondée sur la volatilité historique, une régression Ridge et une Random Forest. L'évaluation respecte l'ordre chronologique et utilise des fenêtres walk-forward croissantes. Les frontières de la cible sont explicitement protégées : une observation d'entraînement n'est conservée que lorsque sa cible à cinq jours se termine dans la période d'entraînement, et une observation de test n'est conservée que lorsque sa cible se termine dans l'année évaluée. La régression Ridge obtient une RMSE plus faible que la baseline dans les quatre années évaluées. La Random Forest n'améliore la baseline qu'en 2022. Cependant, tous les R^2 de Ridge sont négatifs. Le résultat doit donc être interprété comme une amélioration limitée et dépendante de la période, et non comme une preuve d'une prévision très précise ou d'une rentabilité.

Table des matières

1	Question de recherche	3
2	Données et limites des données	3
3	Construction des variables	3
4	Cible et contrôle de la fuite d'information	4
5	Modèles et protocole d'évaluation	5
5.1	Baseline de volatilité historique	5
5.2	Régression Ridge	5
5.3	Random Forest	5
5.4	Évaluation walk-forward	5
6	Résultats	5
7	Tests de robustesse	7
7.1	Fenêtres de volatilité alternatives	7
7.2	Réduction du nombre de variables	7
7.3	Exclusion de 2020	7
8	Simulation de décision	8
9	Limites	8

10 Reproductibilité	8
11 Conclusion	9

1 Question de recherche

La question de recherche est la suivante :

Les informations disponibles à la fin de la date t permettent-elles d'améliorer la prévision de la volatilité réalisée du BTC-USD sur les cinq observations quotidiennes suivantes, par rapport à une baseline simple de volatilité historique ?

Le projet est volontairement une étude de prévision et d'évaluation. Il ne prétend pas prévoir parfaitement le marché et ne contient pas de stratégie de trading autonome.

2 Données et limites des données

Le jeu de données contient des données OHLCV quotidiennes du BTC-USD téléchargées depuis Yahoo Finance avec la bibliothèque `yfinance` [1]. La période demandée va du 1er janvier 2018 au 31 décembre 2025 ; la dernière observation disponible est le 30 décembre 2025.

TABLE 1 – Résumé du jeu de données

Actif	BTC-USD
Source	Yahoo Finance via <code>yfinance</code>
Fréquence	Quotidienne
Première observation	2018-01-01
Dernière observation	2025-12-30
Nombre d'observations	2 921
Fichier brut	<code>data/raw/btc_data.csv</code>
Fichier traité	<code>data/processed/btc_features.csv</code>

L'export CSV contient trois lignes de métadonnées structurelles avant les observations numériques. Ces lignes identifient les colonnes, le ticker et le niveau de date ; elles ne sont pas des observations de marché et sont retirées lors du traitement. Aucune valeur numérique n'est imputée. Les dates sont triées chronologiquement et les doublons sont contrôlés.

Le Bitcoin est échangé en continu, y compris le week-end. L'horizon est donc exprimé en cinq observations quotidiennes et non en cinq jours de cotation classiques. Les données OHLCV quotidiennes ne décrivent pas le chemin intrajournalier des prix. Le fuseau horaire de la source n'est pas enregistré dans le CSV téléchargé, et le volume Yahoo Finance doit être interprété comme un volume agrégé rapporté par le fournisseur plutôt que comme le volume complet de toutes les plateformes d'échange.

3 Construction des variables

Les variables explicatives sont calculées uniquement à partir des informations disponibles à la date de prévision t . La table traitée contient :

- les rendements à un, cinq et vingt jours ;
- la volatilité glissante à cinq, vingt et soixante jours ;
- la volatilité baissière ;
- les moyennes mobiles à vingt et soixante jours ;
- la distance à une moyenne mobile ;
- le drawdown historique et le drawdown récent ;
- l'amplitude récente entre le plus haut et le plus bas ;
- la variation du volume.

Les variables glissantes utilisent uniquement les observations passées. Les calculs de fenêtres glissantes suivent l’approche standard documentée par pandas [4]. Les premières lignes sans historique suffisant sont exclues de la modélisation. La volatilité est calculée à partir des rendements et non des prix bruts.




FIGURE 1 – Prix de clôture du BTC-USD et variables de volatilité historique sélectionnées.

La figure 1 montre pourquoi la volatilité est traitée comme une condition de marché variable et non comme une propriété constante de l’actif. La série contient des périodes calmes et des périodes très turbulentes, ce qui justifie l’évaluation chronologique et les tests de robustesse.

4 Cible et contrôle de la fuite d’information

Pour chaque date de prévision t , la cible est la volatilité réalisée des cinq rendements quotidiens suivants :

$$y_t = \text{std}(r_{t+1}, r_{t+2}, r_{t+3}, r_{t+4}, r_{t+5}), \quad (1)$$

où r_i est le rendement quotidien en pourcentage. La cible est créée en décalant de cinq observations la série de volatilité à cinq jours vers le futur.

La cible possède une date de prévision et une date de fin. Si une observation proche de la fin de 2021 possède une cible qui s’étend jusqu’en janvier 2022, elle ne peut pas être utilisée dans une fenêtre d’entraînement se terminant en 2021. L’évaluation finale enregistre donc la date de fin de la cible et applique la règle suivante :

Une ligne n’est conservée dans une fenêtre que si sa cible complète reste à l’intérieur de la période attribuée à cette fenêtre.

Cette règle empêche les rendements de la période d’évaluation future d’entrer dans les cibles d’entraînement. Les dernières observations sans cible complète à cinq jours sont retirées.

5 Modèles et protocole d'évaluation

Le projet compare trois approches.

5.1 Baseline de volatilité historique

La baseline utilise la volatilité historique récente à cinq jours comme prévision de la volatilité future à cinq jours. Elle est volontairement simple : elle permet de vérifier si les modèles de machine learning apportent une information supplémentaire par rapport à une estimation directe de la volatilité récente.

5.2 Régression Ridge

La régression Ridge est le modèle linéaire régularisé principal. La régularisation est utile ici car les variables de rendement et de volatilité peuvent être corrélées. Le modèle est ajusté avec $\alpha = 1$. Le projet sélectionne explicitement les variables numériques afin que les dates, les identifiants bruts et la cible ne puissent pas entrer accidentellement dans la matrice des variables explicatives. Le cadre général de composition des estimateurs de scikit-learn est documenté dans [2].

5.3 Random Forest

La Random Forest fournit une comparaison non linéaire fondée sur des arbres. Elle permet de vérifier si des relations non linéaires flexibles améliorent les prévisions. Elle n'est pas considérée comme supérieure automatiquement parce qu'elle est plus complexe.

5.4 Évaluation walk-forward

L'évaluation finale utilise des fenêtres chronologiques croissantes :

- entraînement jusqu'à 2021 et évaluation en 2022 ;
- entraînement jusqu'à 2022 et évaluation en 2023 ;
- entraînement jusqu'à 2023 et évaluation en 2024 ;
- entraînement jusqu'à 2024 et évaluation en 2025.

Le mélange aléatoire des observations n'est pas utilisé pour l'évaluation finale. La validation ordonnée dans le temps est cohérente avec les principes de validation des séries temporelles présentés dans la documentation de `TimeSeriesSplit` de scikit-learn [3]. Le projet rend également explicite la frontière de fin de cible au lieu de se limiter à la frontière des dates de prévision.

Les métriques principales sont la MAE, la RMSE, le R^2 , la corrélation de Pearson et la corrélation de rang de Spearman. La MAE est facile à interpréter, tandis que la RMSE pénalise davantage les grandes erreurs. Les corrélations décrivent une association, et non nécessairement une bonne calibration.

6 Résultats

Les valeurs ci-dessous proviennent de `reports/final_walk_forward_results.csv`, généré par le script final avec protection des frontières.

TABLE 2 – Résultats walk-forward avec protection des frontières

Année	Modèle	MAE	RMSE	R^2	Meilleur que la baseline
2022	Baseline historique	1.6937	2.2725	-0.7505	Référence
2022	Ridge	1.3308	1.7508	-0.0390	Oui
2022	Random Forest	1.4432	1.8945	-0.2166	Oui
2023	Baseline historique	1.1338	1.4307	-0.7436	Référence
2023	Ridge	1.0302	1.2166	-0.2609	Oui
2023	Random Forest	1.4712	1.8010	-1.7631	Non
2024	Baseline historique	1.1579	1.5415	-0.5847	Référence
2024	Ridge	1.0571	1.2703	-0.0761	Oui
2024	Random Forest	1.4290	1.6361	-0.7851	Non
2025	Baseline historique	1.0140	1.3309	-0.5390	Référence
2025	Ridge	0.9465	1.1420	-0.1332	Oui
2025	Random Forest	1.2428	1.5309	-1.0362	Non

La Ridge possède la RMSE la plus faible des trois modèles pour chacune des années évaluées. Son avantage par rapport à la baseline est visible à la fois avec la RMSE et avec la MAE. La Random Forest améliore la baseline en 2022, mais elle est moins bonne au cours des trois années suivantes.




FIGURE 2 – Comparaison de la RMSE pour les quatre années d'évaluation walk-forward.

Les valeurs négatives du R^2 de Ridge doivent être interprétées avec prudence. Elles indiquent que Ridge ne dépasse pas une prévision constante fondée sur la moyenne dans cette comparaison, même si elle dépasse la baseline de volatilité historique dans cette expérience. Le résultat constitue donc une amélioration relative par rapport à une baseline pratique, et non une preuve d'une forte capacité prédictive absolue.

Les corrélations de Pearson et de Spearman sont positives mais modestes. Les prévisions présentent une certaine association avec la volatilité future, notamment en 2025, mais les relations ne sont pas assez fortes pour soutenir une prévision fiable dans tous les régimes.



FIGURE 3 – Volatilité future à cinq jours observée et prévue pour chaque année d'évaluation.

7 Tests de robustesse

7.1 Fenêtres de volatilité alternatives

La Ridge a été testée avec des spécifications de volatilité à cinq, vingt et soixante jours. La spécification à soixante jours a produit la MSE annuelle la plus faible parmi les variantes testées dans les expériences de sensibilité précédentes, mais les différences restent modestes. Il est donc préférable de présenter cette fenêtre comme un résultat de sensibilité utile plutôt que comme une fenêtre universellement optimale.

7.2 Réduction du nombre de variables

Une spécification Ridge réduite utilise uniquement le rendement à un jour, le rendement à cinq jours, les volatilités à cinq, vingt et soixante jours, ainsi que le drawdown. Elle reste meilleure que la baseline dans chaque période walk-forward, mais elle n'est pas systématiquement meilleure que la Ridge complète. Cela suggère que l'avantage relatif principal de Ridge ne dépend pas entièrement de chaque variable construite, tandis que la performance exacte dépend encore des variables et de la période.

7.3 Exclusion de 2020

La sensibilité « sans 2020 » est maintenant appliquée à chaque fenêtre d'entraînement walk-forward. L'objectif est de vérifier si le régime de volatilité extrême de 2020 contrôle la conclusion. Le retrait de 2020 modifie légèrement les résultats de Ridge : il dégrade la performance en 2022–2024 et l'améliore légèrement dans la fenêtre 2025. L'effet dépend donc de la période et n'est pas

uniformément favorable ou défavorable.

8 Simulation de décision

Aucune simulation de décision n'est incluse dans cette version. L'expérience de prévision doit être séparée d'une stratégie de trading. Une extension future pourrait étudier un simple ajustement de l'exposition, mais elle devrait spécifier un délai d'exécution, des limites de position, le traitement de la trésorerie, les coûts de transaction, le slippage, le turnover, le levier et le drawdown. La qualité des prévisions devrait toujours être présentée séparément de la performance de la stratégie.

9 Limites

Les principales limites sont les suivantes :

1. l'étude utilise un seul actif, donc les résultats peuvent ne pas se généraliser à d'autres crypto-actifs ou marchés financiers ;
2. les données OHLCV quotidiennes ne représentent pas le chemin intrajournalier ;
3. le fuseau horaire de la source n'est pas enregistré dans le CSV ;
4. le volume Yahoo Finance est un volume agrégé rapporté par le fournisseur ;
5. la structure de marché et la volatilité du Bitcoin ne sont pas stationnaires ;
6. l'échantillon ne contient que quatre fenêtres d'évaluation annuelles ;
7. toutes les valeurs de R^2 de Ridge sont négatives ;
8. aucun coût de transaction ni effet d'exécution n'est inclus, puisqu'aucune stratégie n'est simulée ;
9. les données finales peuvent être révisées si Yahoo Finance est interrogé à nouveau.

Les résultats ne suffisent donc pas à revendiquer une rentabilité générale ou un système de prévision prêt pour la production. La contribution du projet est méthodologique : il montre comment conduire une expérience reproductible, attentive aux fuites d'information et honnête dans un contexte de machine learning financier.

10 Reproductibilité

Le projet est organisé de la façon suivante :

- `data/raw/` : données téléchargées et conservées sans modification ;
- `data/processed/` : variables construites ;
- `scripts/` : collecte, construction des variables, exploration et modélisation ;
- `reports/` : tableaux de résultats, prévisions datées, figures et bibliographie ;
- `docs/` : guide détaillé du projet.

Depuis la racine du dépôt, le workflow principal est :

```
.venv/bin/python 'projects/Market Regime and Risk Lab/scripts/download_data.py'  
.venv/bin/python 'projects/Market Regime and Risk Lab/scripts/create_features.py'  
.venv/bin/python 'projects/Market Regime and Risk Lab/scripts/final_evaluation.py'
```

Les figures du rapport sont générées à partir du jeu de données traité et du CSV final des prédictions. L'évaluation finale écrit le tableau de comparaison dans `reports/final_walk_forward_results.csv` et les prévisions datées dans `reports/final_walk_forward_predictions.csv`.

11 Conclusion

Ce projet montre que la régression Ridge améliore une baseline simple de volatilité historique dans les quatre périodes annuelles walk-forward avec protection des frontières. La Random Forest est moins stable et devient moins bonne que la baseline à partir de 2023. Les tests sur les fenêtres de volatilité et la réduction des variables montrent que la comparaison en faveur de Ridge est raisonnablement stable, mais sa capacité prédictive absolue reste limitée. Les valeurs négatives du R^2 sont particulièrement importantes : le modèle ne doit pas être présenté comme un prévisionneur très précis de la volatilité.

La conclusion la plus défendable est la suivante :

Dans l'échantillon BTC-USD, avec les variables et l'évaluation chronologique utilisés ici, la régression Ridge fournit une amélioration limitée et dépendante de la période par rapport à la baseline de volatilité historique. Les résultats ne démontrent ni une précision universelle ni une rentabilité de trading.

Références

- [1] Ran Aroussi. yfinance : Yahoo finance market data downloader. GitHub repository, 2025. Accessed 2026-08-07.
- [2] scikit-learn developers. Pipelines and composite estimators, 2025. Accessed 2026-08-07.
- [3] scikit-learn developers. Timeseriessplit documentation, 2025. Accessed 2026-08-07.
- [4] The pandas development team. pandas.dataframe.rolling documentation, 2025. Accessed 2026-08-07.